No AI
AI 4 Requests/s per GPU
AI 8 Requests/s per GPU